Технологии глубокого обучения и нейронных сетей

Лекция 3

Обучение языковых моделей

Петр Георгиевич Меньших · МТУСИ

Модель — семейство распределений.

Обучение — выбор члена семейства, при котором данные наиболее правдоподобны.

Дальше меняется только богатство семейства и масштаб данных.

Сегодня второе и третье предложения: как выбирают члена семейства и что меняет масштаб.

Отсылки второй лекции

НА ЛЕКЦИИ 2 ГОВОРИЛИ ПРО:

1. Как подбирают 600 миллионов параметров
2. Энкодеры и декодеры
3. Законы масштабирования
4. Почему e5 выиграл поиск по абзацам

Это и есть план пары.

Корпус

Веб-страницы

Основная масса. Отфильтрованный и очищенный веб.

Код

Доля растет с каждым поколением: код учит рассуждать по шагам.

Книги и статьи

Мало, но длинные и качественные.

Диалоги и инструкции

Добавляют ближе к концу обучения.

ЧТО ДЕЛАЮТ С ДАННЫМИ ДО ОБУЧЕНИЯ

Фильтрация: мусор, дубли, запрещенное

↓

Удаление повторов

↓

Смесь в пропорциях

Qwen3 обучена на 36 триллионах токенов на 119 языках.

«Война и мир» из лабораторных это 0.9 миллиона токенов: в сорок миллионов раз меньше. Доля русского в корпусах несколько процентов.

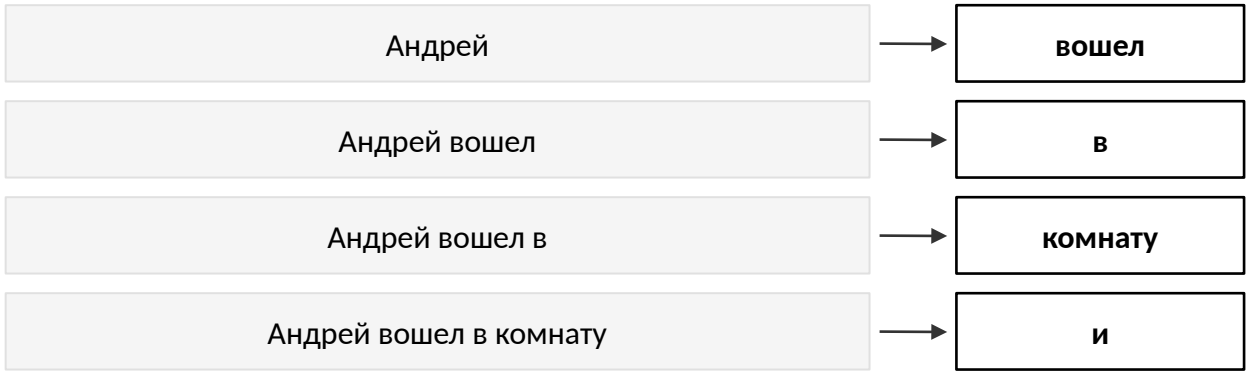
Корпус это и есть «данные» правдоподобие которых измеряют.
Их столько, что большинство текстов модель видит один раз.

Задача у обучения одна: научить предсказывать следующий токен

ПОТОК ТОКЕНОВ ИЗ КОРПУСА



ИЗ КАЖДОЙ ПОЗИЦИИ ОКНА ОБУЧАЮЩИЙ ПРИМЕР



Ответ уже написан в тексте. Разметки руками нет, поэтому данных может быть МНОГО.

Та же задача, что у биграмм из лабораторной 1. Разница в двух вещах: контекст не одно слово, а тысячи токенов, и семейство трансформеров, а не таблица счетчиков.

Все, что модель умеет, вырастает из этой одной задачи.

Лосс

$$\mathcal{L}(\theta) = -\frac{1}{N}\sum_{i} \log\, p_\theta(t_{i+1} \mid t_1, \ldots, t_i)$$

p: вероятность, которую модель дала настоящему следующему токену.

Минус логарифм: чем меньше вероятность, тем больше штраф.

1/N и сумма: среднее по всем позициям корпуса.

Это уже было

Кросс-энтропия с первой лекции.
Минус логарифм правдоподобия текста из лабораторной 1.
Те же счетчики, только вместо таблицы 600 миллионов параметров.
В коде одна строка: cross_entropy.

Обучение это уменьшение одного числа. Формула не новая, новое только то, что стоит за p.

Числовой пример

КНЯЗЬ АНДРЕЙ ВОШЕЛ В КОМНАТУ: ИЗ СКОЛЬКИХ ВАРИАНТОВ КАК БУДТО ВЫБИРАЛА QWEN3

« Андр»	«ей»	« во»	«шел»	« в»
p = 0.02	p = 0.88	p = 0.001	p = 0.22	p = 0.84
из 50	**из 1.1**	**из 1000**	**из 4.5**	**из 1.2**

в среднем из 12 вариантов на каждом шаге

Это перплексия, та же, что вы считали для биграмм в лабораторной 1. Среднее геометрическое: перемножить и взять корень пятой степени.

Лосс это логарифм числа вариантов: ln 12 = 2.52. Логарифмы складываются, поэтому в формуле он, а не сами варианты.

Наугад из 151 936

Худший случай: из всего словаря на каждом шаге.

Идеальная модель

Из одного варианта. Такой не бывает: текст не предопределен.

Дорого стоит то, что нельзя угадать: имя после «Князь», глагол после имени. Дешево то, что доопределено.

Градиентный спуск

Пачка окон
из корпуса
→
Лосс
на пачке
→
Градиент
по всем параметрам
→
Сдвиг
против градиента

И снова, миллионы раз. Та же цепочка, что для перцептрона на первой лекции.

В заметке к лекции: оптимизатор AdamW, разогрев и косинусное расписание шага, обрезка градиента.

ЧТО МЕНЯЕТСЯ С МАСШТАБОМ

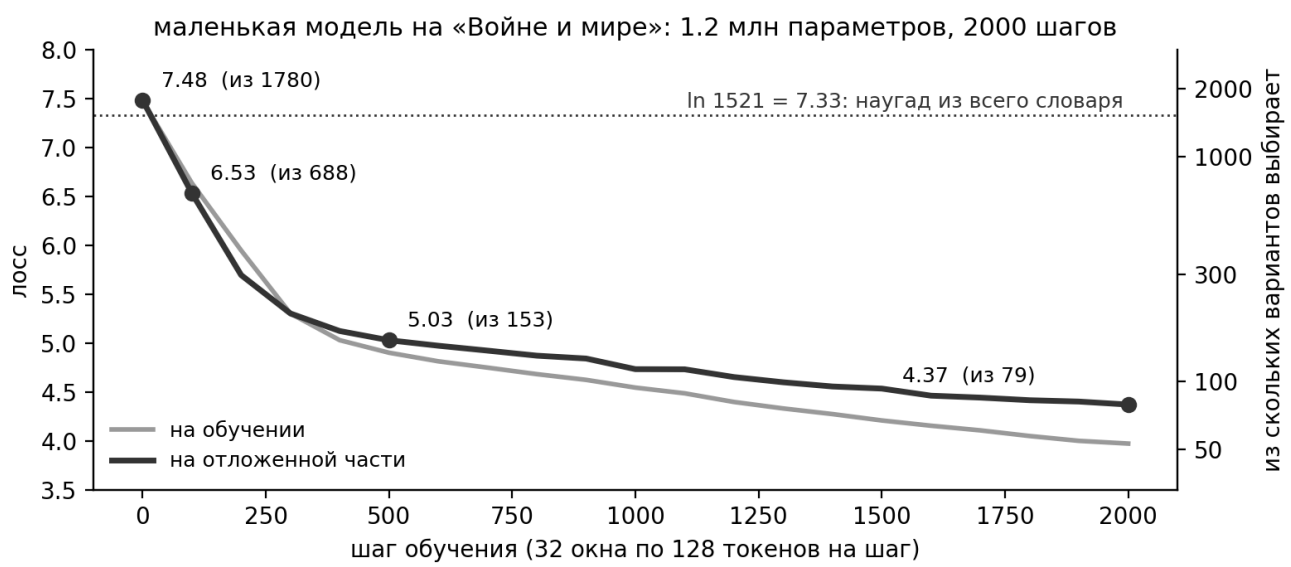
Параметров миллиарды
а не десять

Шагов миллионы
а не сто

Тысячи видеокарт одновременно
каждая со своей пачкой, раз в шаг обмен градиентами

Со времен перцептрона на уровне принципа не изменилось ничего. Изменились три числа.

Кривая обучения



ЗАТРАВКА «КНЯЗЬ АНДРЕЙ», ТЕМПЕРАТУРА 0.8

шаг 0

увиддруга ва светсебе позицмноядсами головельсмотря

шаг 100

ся и то мыслней е слышма ивон кажней про которые

шаг 500

что бы отец и придать что ж мне блаженно не хотал между тем что он чувствовал

шаг 2000

подъехал к местам бенигбочки и началый пехотный совет от линии

Модель выбирала из 1780 вариантов, теперь из 79. Все, что она умеет, появилось из уменьшения одного числа. В лабораторной надо будет построить такую кривую.

Цена

работа ≈ 6 × параметры × токены

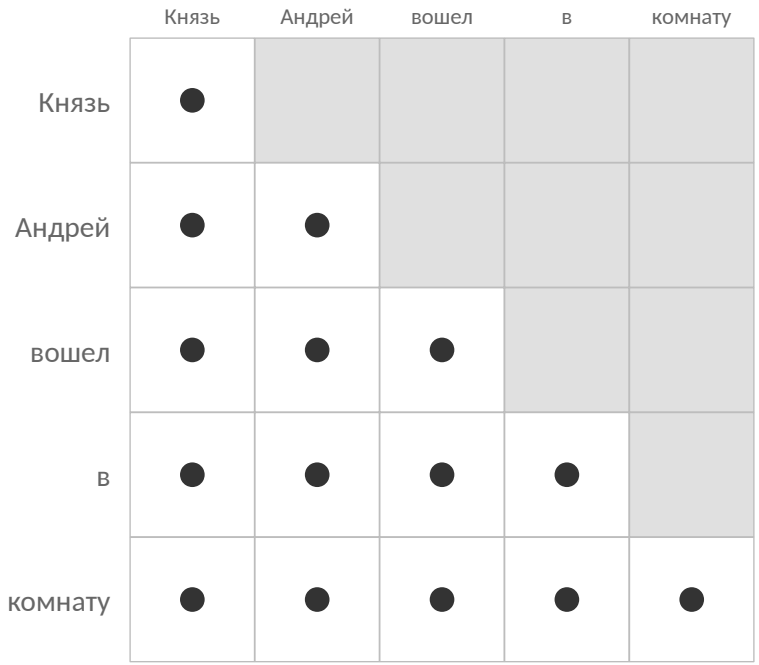
прямой проход два действия на параметр на токен, обратный четыре

	параметры × токены	операций	время
Маленькая модель из лабораторной	1.2 млн × 8 млн	$6 \cdot 10^{13}$	секунды арифметики
Qwen3-0.6B	0.6 млрд × 36 трлн	$1.3 \cdot 10^{23}$	порядка ста тысяч часов одной H100
Llama 3 405B	405 млрд × 15.6 трлн	$3.8 \cdot 10^{25}$	30.8 миллиона часов H100 по отчету Meta

H100 на практике выдает 3–4 · 10^{14} операций в секунду. Подстановка чисел Llama в формулу сходится с отчетом.

С нуля обучают десяток компаний в мире. Все остальные берут готовые веса и дообучают: токенов меньше на четыре-пять порядков.

Маска есть: декодер



серое запрещено: токен видит себя и то, что слева

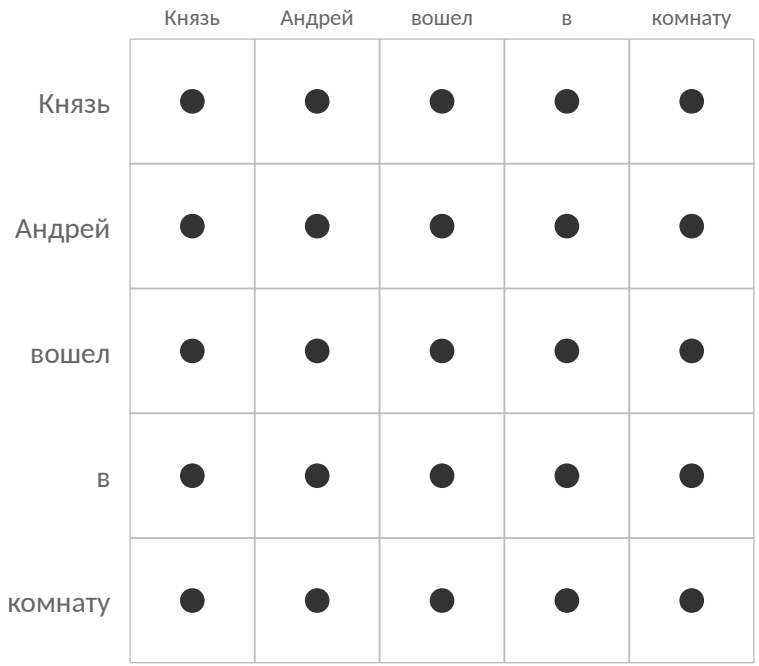
Декодер

Задача обучения: следующий токен.
Умеет генерировать: его ровно этому учили.
GPT, Llama, Qwen, все чат-модели.

Все, что было в предыдущем блоке, про него.

Лосс требует предсказывать то, что справа, глядя только влево. А если разрешить смотреть в обе стороны?

Маски нет: энкодер



все клетки открыты: токен видит весь текст

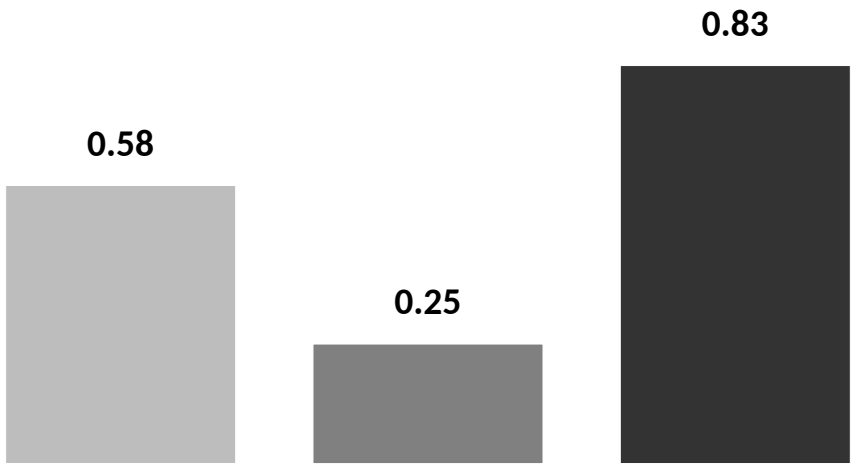
Энкодер

Задача обучения: закрытое слово.
«Князь Андрей [MASK] в комнату» → «вошел».
Генерировать нельзя: ответ был бы виден.
BERT, 2018, и потомки: среди них e5 из лабораторной 2.

Восстановить слово, видя обе стороны, это задача про понимание, а не про продолжение.

Почему e5 выиграл в лабораторной

RECALL@5 ИЗ ЭТАЛОНА ЛАБОРАТОРНОЙ 2



Причина архитектурная

У декодера вектор первого слова абзаца не знает, о чем абзац: вправо смотреть нельзя. Среднее из «ничего не знаю» и «знаю все» хуже простой таблицы. У энкодера каждое слово видит весь абзац.

Причина обучающая

e5 дополнительно учили на парах «вопрос, подходящий абзац»: косинус стал близостью по смыслу. У декодера близость векторов побочный продукт задачи следующего токена.

Числа второй лабораторной.

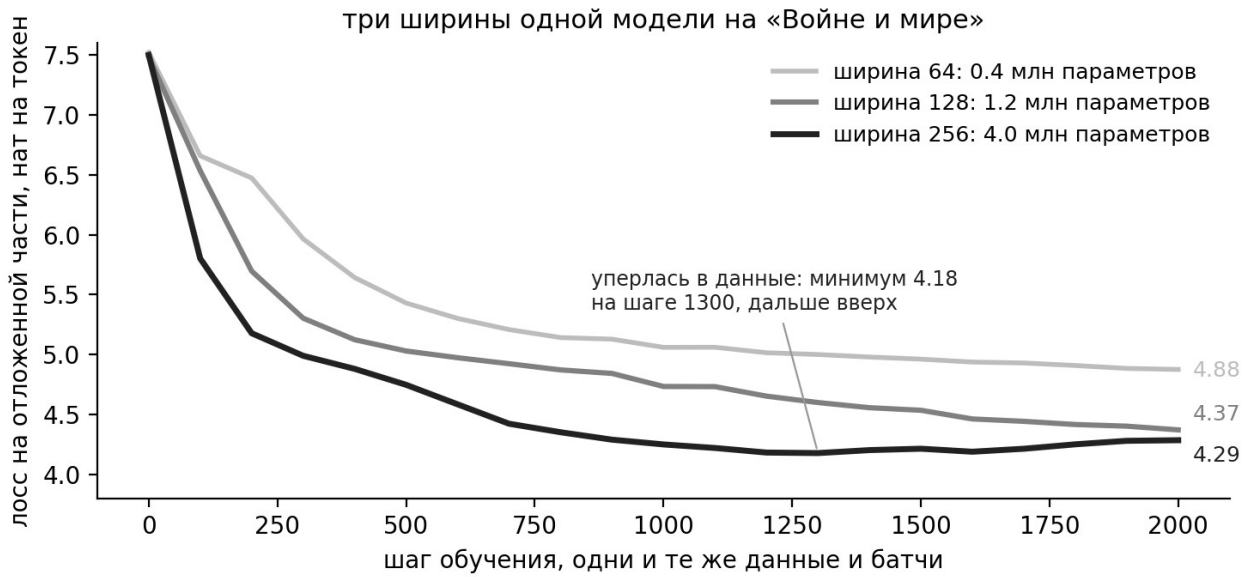
Три семейства архитектур

	Маска	Задача обучения	Что умеет	Где в курсовой
Декодер	есть	следующий токен	генерировать	ответ; модель до 4B
Энкодер	нет	закрытое слово	понимать, сравнивать, классифицировать	retrieval, классификация, проверка; до 600M
Энкодер-декодер	у половины	вход целиком, выход по токену	перевод, пересказ: T5	редко

Энкодер маленький и быстрый: его зовут на каждый абзац документа. Декодер большой: его зовут один раз на ответ.

Для поиска энкодер, для ответа декодер. В курсовой нужны оба, лимиты на них разные именно поэтому.

Обучение на трех примерах



Слева: наш закон в миниатюре. Три одинаковые модели шириной 64, 128 и 256, те же данные и шаги. Самая широкая с 1300-го шага переобучается: упёрлась в ось данных.

Kaplan, 2020

Лосс падает степенным законом по параметрам, данным и вычислениям, пока две другие оси не упираются.
В логарифмических осях это прямые. Удесятерение вычислений снижает лосс примерно на 11 %.
Эмпирический закон, как в физике: позволяет планировать обучение заранее.

Чем больше, тем лучше, с убывающим выигрышем, и это можно измерить заранее.

Сколько данных на параметр

Модель	Параметры	Токенов обучения	Токенов на параметр
GPT-3, 2020	175 млрд	300 млрд	1.7
Chinchilla, 2022	70 млрд	1.4 трлн	20
Llama 3 8B, 2024	8 млрд	15 трлн	около 1900
Qwen3-0.6B, 2025	0.6 млрд	36 трлн	60 000

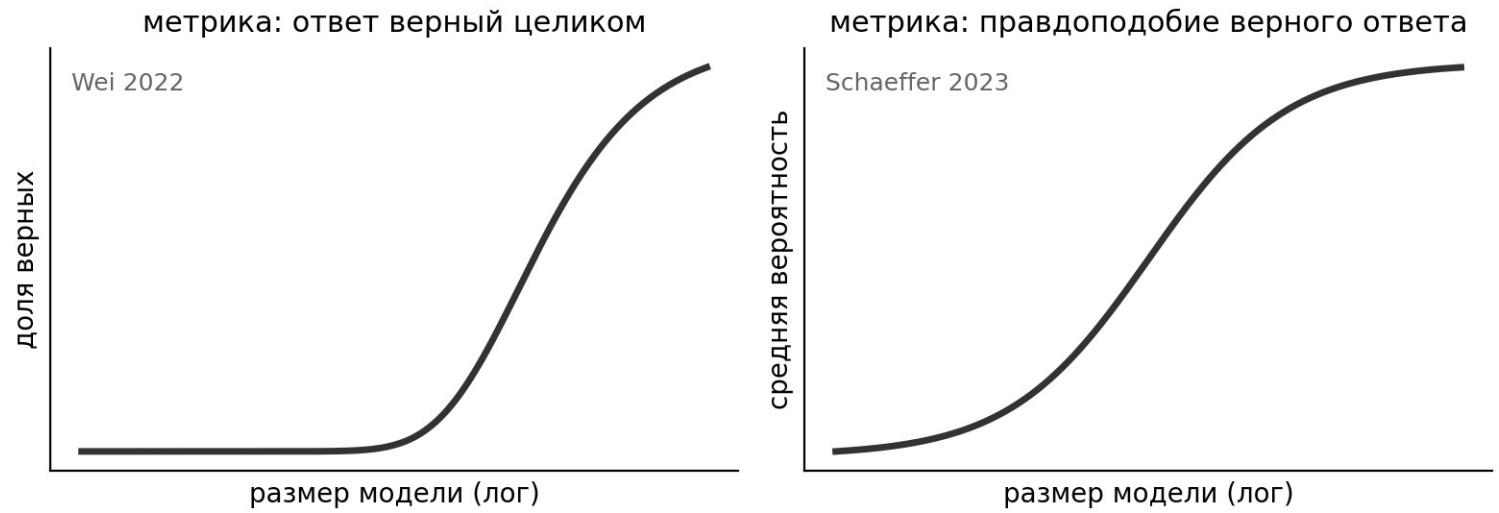
Почему переучивают

Модель обучают один раз, запускают миллиарды раз. Каждый запуск стоит пропорционально числу параметров. Маленькая переученная модель дешевле в работе, чем большая недоученная, а лосс продолжает медленно падать.

Отсюда ответ на вопрос второй лекции, почему у больших моделей шире вектор: ширину подбирают из бюджета по тем же законам.

Оптимум по обучению не равен оптимуму по эксплуатации. Например модели до 4B в курсовой переучены.

Эмерджентность с оговоркой



Одни и те же модели. Если ответ засчитывается только целиком, вероятность верного ответа из пяти цифр растет как пятая степень и выглядит скачком.

Что остается верным

С масштабом появляются способности, которых не было. Какие и при каком размере, предсказывать пока не умеют.
Что перестает быть верным: разговор о «фазовых переходах» и о том, что в модели что-то «щелкает».

Прежде чем верить графику со скачком, спросите, что отложено по оси y.

Что это значит для курсовой

МОДЕЛЬ ДО 4B ДЕЛАЕТ ХОРОШО

Узкая задача с опорой на контекст: факты лежат в промпте

Извлечение полей и классификация

Переформулирование и структурирование

Следование заданному формату

ДЕЛАЕТ ПЛОХО

Факты из собственной памяти

Длинные цепочки рассуждений

Арифметика

Редкие языки и термины

все это закрывается кодом вокруг модели: retrieval, проверка, инструменты, декомпозиция.

Модель делает узкую работу, остальное делает код.

Как читать карточку модели

Qwen3-30B-A3B-Instruct

30B

Всего 30 миллиардов параметров. Столько нужно памяти.

A3B

На каждом токене работают 3 миллиарда. Смесь экспертов: полносвязная сеть разбита на 128 кусков, маршрутизатор выбирает 8. Память как у 30B, скорость как у 3B.

Instruct

Прошла дообучение, отвечает. Base продолжает текст; Thinking рассуждает перед ответом.

Еще два поля: длина контекста и лицензия. Открытые веса можно скачать и поставить у себя, модели по API нельзя.

Два числа в названии это ответ, почему модель на 30 миллиардов работает со скоростью модели на три.

Семейства

Открытые веса	Кто	Размеры	У себя
Qwen	Alibaba	0.6B – 235B	да, в курсе с ней работаем
Llama	Meta	1B – 405B	да
Gemma	Google	1B – 27B	да
Mistral, DeepSeek	Mistral AI, DeepSeek	до сотен миллиардов	да

По API	Кто	У себя
GPT	OpenAI	нет
Claude	Anthropic	нет
Gemini	Google	нет

Без рейтингов: они устареют к сессии. Актуальное на странице модели на Hugging Face и на публичных лидербордах, ссылки в заметке.

Для курсовой нужна левая группа.
Правая допустима как необязательный компонент с фолбэком на локальную модель.

ДЕМО

Под капотом генерации

1

Лосс на одном предложении

«Князь Андрей вошел в комнату и сел у окна»: вероятность каждого настоящего токена. В среднем 2.08 нат. «Ня» после «К» стоит 8.4, «у» после « комнат» 0.01.

2

Один forward pass руками

Логиты, softmax, десятка кандидатов, выбор. После затравки «сказал» 0.066; после «сказал» двоеточие 0.51; после двоеточия кавычка 0.55. Три шага, и это вся генерация.

3

Температура и две модели

«сказал» 0.32 при 0.3, 0.07 при 1.0, 0.03 при 1.5. Жадная генерация зацикливается с 26-го токена. Base на вопрос отвечает вопросами, Instruct отвечает.

Вывод по аналогии

КАК ВЫГЛЯДИТ

Параметр по аналогии

У десяти похожих библиотек есть timeout, у этой нет. Код не запускается, и это еще хороший исход.

Синтаксис другой версии

Код под старый API без предупреждения, что версия имеет значение. Старых примеров в корпусе больше.

«Последняя версия» после отсечки

Python 3.14 вышел в октябре 2025. Модель с отсечкой 2024 года назовет 3.12 и не оговорится.

МЕХАНИЗМ, ДВА

Лосс награждает правдоподобное

Не проверенное. Если в корпусе сто библиотек с timeout, у сто первой он «есть». Второго члена в лоссе, который штрафовал бы за несоответствие документации, не существует.

Веса заморожены на дате отсечки

Все, что «из головы», лежит в параметрах и не обновляется между запросами. Границы своих знаний модель не чувствует: в корпусе тексты не помечены датой незнания.

Та же формула, что во Вскрытии 1, с другой стороны: там выдумала целиком, здесь перенесла с похожего.

Правила воссоздания

Проверяемо по первоисточнику

Документация, changelog, страница релиза.

Виден донор или разрыв по дате

Откуда модель перенесла несуществующее, или факт изменился с момента обучения.

Модель не оговорилась

Без «возможно» и «проверьте документацию». Ответ подан как факт.

Воспроизводимо локально

Чат-версия Qwen3-0.6B или другая локальная: промпт, число прогонов, доля ошибок.

Идеальный кадр: тот же вопрос с куском документации в промпте, и ответ правильный. Шаблон cases/protocol_template.md, три рецепта рядом.

ВЫВОД

Факты, версии и даты модели дают в контексте, а не спрашивают из памяти. Документация в промпте побеждает документацию в весах.

Лабораторная 3: обучение языковой модели руками

ТЗ в репозитории, папка assignments/03.

Своя маленькая модель

Данные: «Война и мир», токены из вашего BPE лабораторной 2

Декодер на PyTorch, внимание по формуле второй лекции

2000 шагов: кривая лосса на обучении и на отложенной части

Образцы с затравки «князь андрей» на шагах 0, 100, 500, 2000

Генерация на своей модели

Своя generate: температура, top-p, жадный выбор

Четыре режима на одной затравке: жадный, 0.7, 1.5, top-p 0.9

Шаг, на котором жадная генерация зацикливается

В курсовую: параметры генерации как конфигурация эксперимента

Одна модель: от случайных весов до текста и параметров генерации. CI как в работе 2.

Для любознательных

lectures/03/how-training-works.md

Лосс и перплексия формулами, нат против бита
Батч, шаг, AdamW и расписание, обрезка градиента
Оценка 6ND с тремя примерами
Kaplan и Chinchilla: степенные законы и 20 токенов на параметр
Эмерджентность и спор о метриках
Задача энкодера и контрастивный лосс e5
Температура, top-p и почему жадный выбор зацикливается

> На лекции не нужно, на экзамене пригодится.

Спасибо

СЛЕДУЮЩАЯ ЛЕКЦИЯ

Как модель становится ассистентом: что делают с Base-моделью, чтобы она отвечала. SFT, обучение на предпочтениях, LoRA, reasoning-модели.

github.com/pmenshih/tgo-course

Материалы, ноутбуки демонстраций, задания лабораторных, шаблон протокола поломки